Laporan Praktikum 3
Classification dengan Ensemble Method dan Class Imbalance
Kadek Nathania Gavrila Astika – 5054251050

1. Latar Belakang

Penipuan kartu kredit merupakan salah satu masalah utama dalam sistem pembayaran digital. Setiap transaksi fraud yang tidak terdeteksi menimbulkan kerugian finansial langsung bagi nasabah maupun bank, sehingga diperlukan sistem yang mampu mengenali transaksi mencurigakan secara otomatis. Machine learning, khususnya klasifikasi, banyak digunakan untuk tugas ini karena dapat mempelajari pola transaksi dari data historis.

Tantangan utama dalam deteksi fraud adalah ketidakseimbangan kelas (class imbalance). Jumlah transaksi fraud jauh lebih sedikit dibandingkan transaksi normal. Pada kondisi ini, model klasifikasi cenderung condong memprediksi kelas mayoritas, sehingga dapat mencapai accuracy yang sangat tinggi tetapi gagal mendeteksi fraud yang justru menjadi tujuan utama.

Praktikum ini bertujuan untuk: (1) menganalisis distribusi kelas pada dataset Credit Card Fraud Detection; (2) menerapkan teknik penanganan class imbalance, yaitu oversampling dengan SMOTE dan undersampling dengan Random Undersampling; serta (3) membangun dan membandingkan dua ensemble method, yaitu Random Forest dan XGBoost (Gradient Boosting), dengan metrik evaluasi yang sesuai untuk data tidak seimbang.

2. Dataset

Dataset yang digunakan adalah Credit Card Fraud Detection dari Kaggle (kaggle.com/mlg-ulb/creditcardfraud). Dataset ini berisi transaksi kartu kredit pemegang kartu di Eropa selama dua hari pada September 2013, dengan total 284.807 transaksi dan 31 kolom. Karakteristik atributnya ditunjukkan pada Tabel 1.

Tabel 1. Deskripsi atribut dataset

Atribut	Keterangan
Time	Selisih waktu (detik) antara transaksi dengan transaksi pertama pada dataset
V1 – V28	Fitur hasil transformasi PCA yang telah dianonimkan untuk menjaga kerahasiaan data
Amount	Nominal transaksi
Class	Target: 0 = transaksi normal, 1 = transaksi fraud

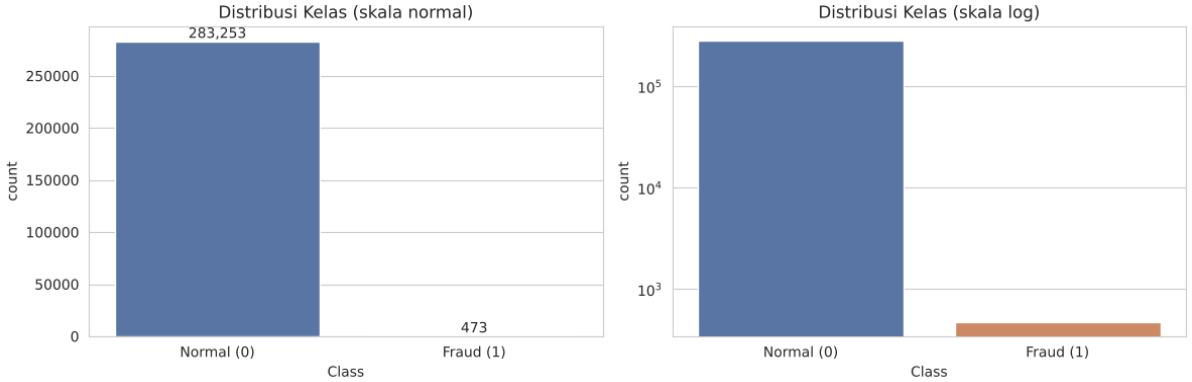
Pemeriksaan kualitas data menunjukkan bahwa dataset tidak memiliki missing values. Namun, ditemukan 1.081 baris duplikat (1.062 transaksi normal dan 19 transaksi fraud) yang identik di seluruh fitur dan labelnya. Setelah duplikat dihapus (alasannya dijelaskan pada Bagian 3.1), dataset berisi 283.726 transaksi.

a. Distribusi Kelas Awal

Distribusi kelas setelah penghapusan duplikat ditunjukkan pada Tabel 2 dan Gambar 1.

Tabel 2. Distribusi kelas pada dataset

Kelas	Jumlah	Persentase
0 – Normal	283.253	99,8333%
1 – Fraud	473	0,1667%
Total	**283.726**	**100%**



Gambar 1. Distribusi kelas dalam skala normal (kiri) dan skala logaritmik (kanan)

Dataset ini sangat tidak seimbang (highly imbalanced). Transaksi fraud hanya sekitar 0,17% dari seluruh data, dengan rasio normal terhadap fraud sekitar 599 : 1. Pada grafik skala normal, batang kelas fraud bahkan hampir tidak terlihat. Kondisi ini menyebabkan model cenderung mempelajari pola transaksi normal saja: model yang selalu menebak "normal" pun sudah memperoleh accuracy sekitar 99,83% tanpa mendeteksi satu pun fraud. Oleh karena itu, penanganan class imbalance dan pemilihan metrik evaluasi yang tepat menjadi sangat penting.

3. Metodologi

Seluruh eksperimen dilakukan menggunakan Python dengan library pandas, scikit-learn, imbalanced-learn, dan xgboost. Seluruh proses acak menggunakan random_state=42 agar hasil dapat direproduksi.

a. Praproses Data

- Penghapusan duplikat. Jika duplikat dibiarkan, salinan baris yang sama dapat masuk ke data latih dan data uji sekaligus. Simulasi menggunakan cara pembagian data yang sama menunjukkan bahwa tanpa penghapusan, 344 baris data uji memiliki salinan persis di data latih, termasuk 8 dari 98 transaksi fraud (8,2%). Model dapat "menghafal" baris tersebut sehingga hasil evaluasi menjadi terlalu optimis (data leakage). Karena salinan kedua tidak menambah informasi baru, duplikat dihapus sebelum pembagian data.
- Pembagian data latih dan data uji dengan rasio 80:20 menggunakan stratified split (stratify=y). Data latih berisi 226.980 transaksi (378 fraud), sedangkan data uji berisi 56.746 transaksi (95 fraud). Proporsi fraud pada kedua bagian tetap sekitar 0,17%, sesuai distribusi asli.
- Standardisasi fitur Time dan Amount menggunakan StandardScaler. Random Forest dan XGBoost sebenarnya tidak memerlukan scaling, tetapi SMOTE menghitung jarak antartitik data. Kedua fitur ini memiliki rentang nilai yang jauh lebih besar dibandingkan V1–V28

sehingga dapat mendominasi perhitungan jarak. Scaler hanya di-fit pada data latih, lalu digunakan untuk mentransformasi data latih dan data uji.

b. Penanganan Class Imbalance

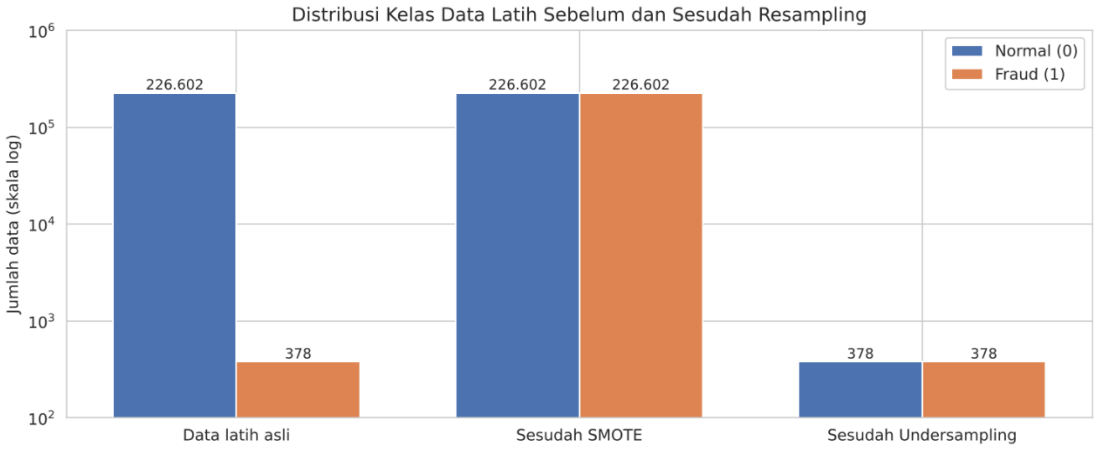
Dua pendekatan resampling digunakan dan hanya diterapkan pada data latih. Data uji tetap menggunakan distribusi asli agar evaluasi mencerminkan kondisi nyata.

- **Oversampling dengan SMOTE**

  SMOTE (Synthetic Minority Over-sampling Technique) membuat sampel fraud sintetis. Untuk setiap sampel fraud, SMOTE mencari k tetangga terdekat (k=5) dari kelas yang sama, lalu membuat sampel baru di antara sampel tersebut dan salah satu tetangganya. Berbeda dengan random oversampling yang hanya menyalin data, SMOTE menghasilkan contoh fraud yang lebih bervariasi.

- **Undersampling dengan Random Undersampling**

  Sampel kelas normal dibuang secara acak sampai jumlahnya sama dengan kelas fraud. Teknik ini tidak membuat data baru, tetapi membuang sebagian besar informasi kelas normal.



Gambar 2. Distribusi kelas data latih sebelum dan sesudah resampling (skala logaritmik)

Seperti terlihat pada Gambar 2, SMOTE memperbesar data latih menjadi 453.204 baris dengan rasio 1:1, sedangkan undersampling memperkecil data latih menjadi hanya 756 baris. Artinya, undersampling membuang 226.224 transaksi normal atau 99,83% dari data normal pada data latih.

c. Model Klasifikasi

Dua ensemble method digunakan dengan parameter sederhana tanpa hyperparameter tuning, karena fokus praktikum adalah membandingkan efek penanganan class imbalance:

- Random Forest (bagging): kumpulan decision tree yang dibangun secara paralel dan independen, masing-masing pada sampel bootstrap dan subset fitur acak. Prediksi akhir diambil dari voting mayoritas. Parameter: n_estimators=100.
- XGBoost (Gradient Boosting): pohon dibangun secara berurutan, dan setiap pohon baru memperbaiki kesalahan pohon sebelumnya. XGBoost dipilih karena merupakan implementasi Gradient Boosting yang dapat berjalan paralel sehingga efisien untuk dataset berukuran besar. Parameter: n_estimators=300, learning_rate=0,1, max_depth=6, tree_method=hist.

Setiap model diuji tanpa dan dengan penanganan class imbalance, sehingga terdapat enam skenario (Tabel 3). Parameter model dibuat sama di setiap skenario, dan seluruh skenario dievaluasi pada data uji yang sama agar perbandingan adil.

Tabel 3. Skenario eksperimen

Strategi	Random Forest	XGBoost
Tanpa penanganan (baseline)	Skenario 1	Skenario 4
Oversampling (SMOTE)	Skenario 2	Skenario 5
Undersampling (Random Undersampling)	Skenario 3	Skenario 6

d. Metrik Evaluasi

Karena fokus deteksi adalah kelas fraud, precision, recall, dan F1-score dihitung khusus untuk kelas fraud (kelas 1), bukan rata-rata berbobot. Metrik yang digunakan adalah:

- Precision: proporsi transaksi yang diprediksi fraud yang benar-benar fraud. Precision rendah berarti banyak false alarm.
- Recall: proporsi transaksi fraud yang berhasil dideteksi. Recall rendah berarti banyak fraud yang lolos.
- F1-score: rata-rata harmonik precision dan recall, untuk mengukur keseimbangan keduanya.
- AUC-ROC: kemampuan model membedakan fraud dan normal pada berbagai threshold, dihitung dari probabilitas prediksi kelas fraud.
- Confusion matrix: distribusi prediksi benar dan salah, yaitu TP (fraud terdeteksi), FN (fraud lolos), FP (false alarm), dan TN.

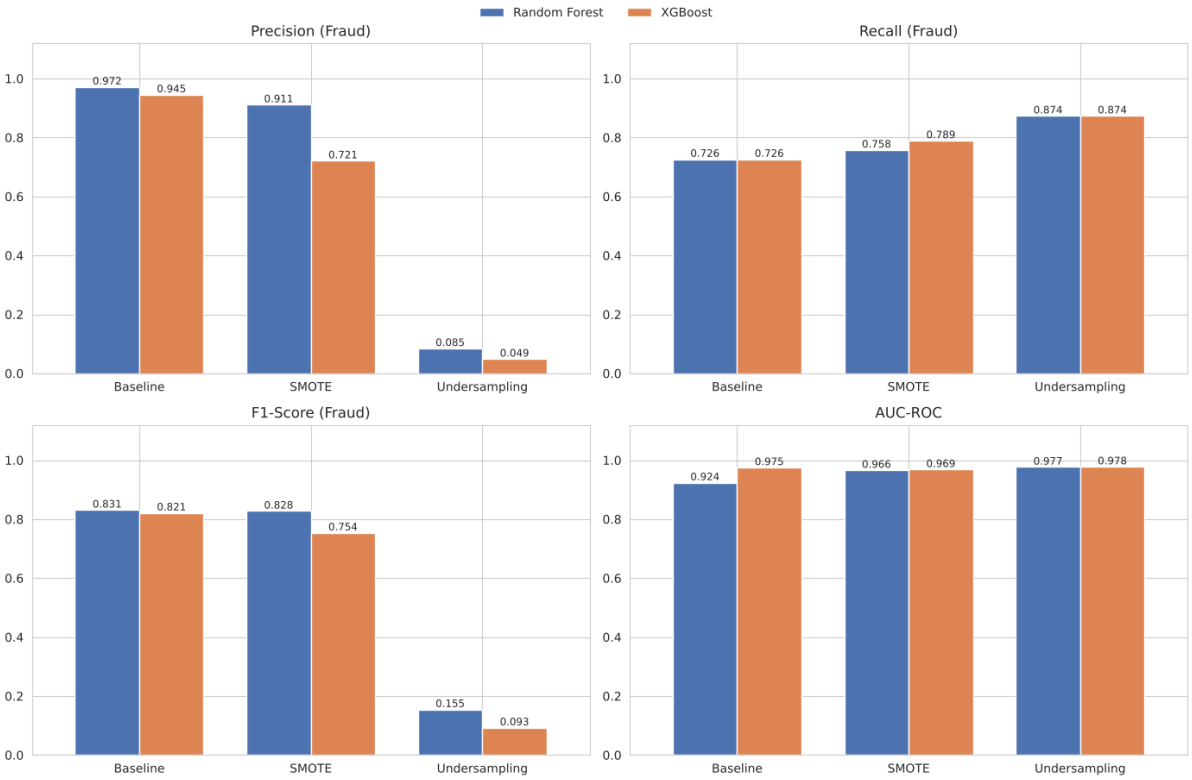
4. Hasil dan Pembahasan

a. Performa Model

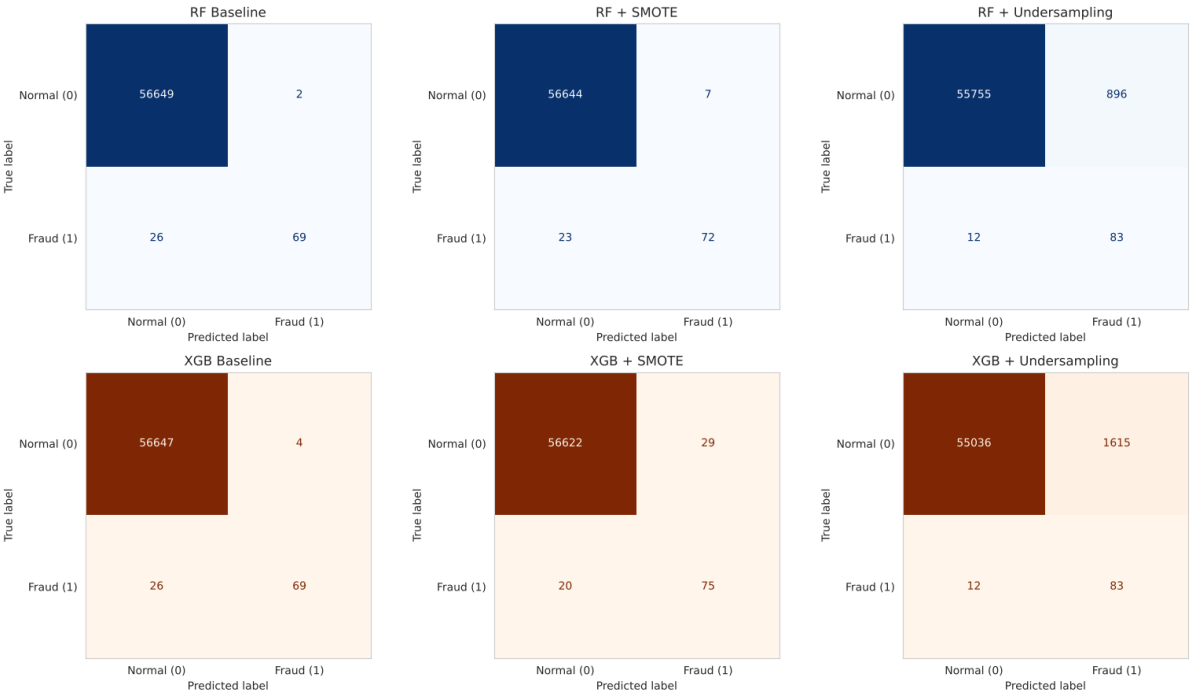
Tabel 4 merangkum performa keenam skenario pada data uji (56.746 transaksi, 95 di antaranya fraud).

Tabel 4. Performa model pada data uji (precision, recall, dan F1-score untuk kelas fraud)

Skenario	Accuracy	Precision	Recall	F1-score	AUC-ROC	TP	FP	FN
RF Baseline	0,9995	**0,9718**	0,7263	**0,8313**	0,9239	69	**2**	26
RF + SMOTE	0,9995	0,9114	0,7579	0,8276	0,9662	72	7	23
RF + Undersampling	0,9840	0,0848	**0,8737**	0,1546	**0,9767**	**83**	896	**12**
XGB Baseline	0,9995	**0,9452**	0,7263	**0,8214**	0,9753	69	**4**	26
XGB + SMOTE	0,9991	0,7212	0,7895	0,7538	0,9685	75	29	20
XGB + Undersampling	0,9713	0,0489	**0,8737**	0,0926	**0,9778**	**83**	1.615	**12**



Gambar 3. Perbandingan precision, recall, F1-score, dan AUC-ROC kelas fraud untuk setiap strategi



Gambar 4. Confusion matrix keenam skenario (baris atas: Random Forest, baris bawah: XGBoost)

b. Perbandingan Tanpa dan Dengan Penanganan Class Imbalance

- **Baseline**

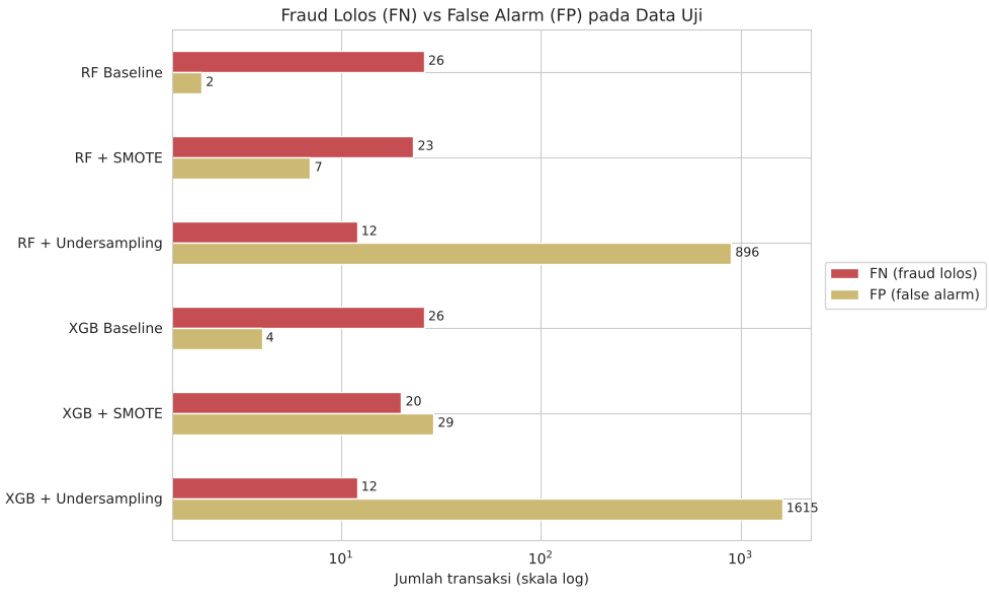
Tanpa penanganan class imbalance, kedua model sudah menunjukkan performa yang cukup baik. Precision-nya tinggi (94–97%) dengan false alarm yang sangat sedikit (2–4 transaksi). Namun, recall hanya 72,63%, artinya 26 dari 95 transaksi fraud masih lolos tidak terdeteksi.

- **SMOTE**

  Pada kedua model, SMOTE meningkatkan jumlah fraud yang terdeteksi: Random Forest dari 69 menjadi 72, dan XGBoost dari 69 menjadi 75. Akan tetapi, dampaknya terhadap false alarm berbeda. Pada Random Forest, kenaikan recall hanya dibayar dengan 5 false alarm tambahan, sehingga F1-score tetap setara dengan baseline (0,8276 vs 0,8313), sementara AUC-ROC meningkat cukup jelas (0,9239 menjadi 0,9662). Pada XGBoost, false alarm melonjak dari 4 menjadi 29 sehingga precision turun ke 72,12% dan F1-score turun dari 0,8214 menjadi 0,7538. Kemungkinan penyebabnya, boosting sangat fokus memperbaiki contoh yang sulit sehingga lebih mudah terlalu percaya pada pola dari data fraud sintetis.

- **Undersampling**

  Teknik ini menghasilkan recall tertinggi pada kedua model, yaitu 83 dari 95 fraud terdeteksi (87,37%). Namun, false alarm meledak menjadi 896 transaksi (Random Forest) dan 1.615 transaksi (XGBoost), dengan precision hanya 8,48% dan 4,89%. Artinya, hanya sekitar 1 dari 12 (RF) dan 1 dari 20 (XGB) transaksi yang ditandai fraud yang benar-benar fraud. Hal ini terjadi karena model hanya dilatih pada 756 baris data, sehingga tidak sempat mempelajari variasi transaksi normal yang sangat beragam. Selain itu, model terbiasa melihat fraud sebanyak 50% dari data latih, padahal pada data nyata fraud hanya sekitar 0,17%.



Gambar 5. Jumlah fraud yang lolos (FN) dan false alarm (FP) setiap skenario (skala logaritmik)

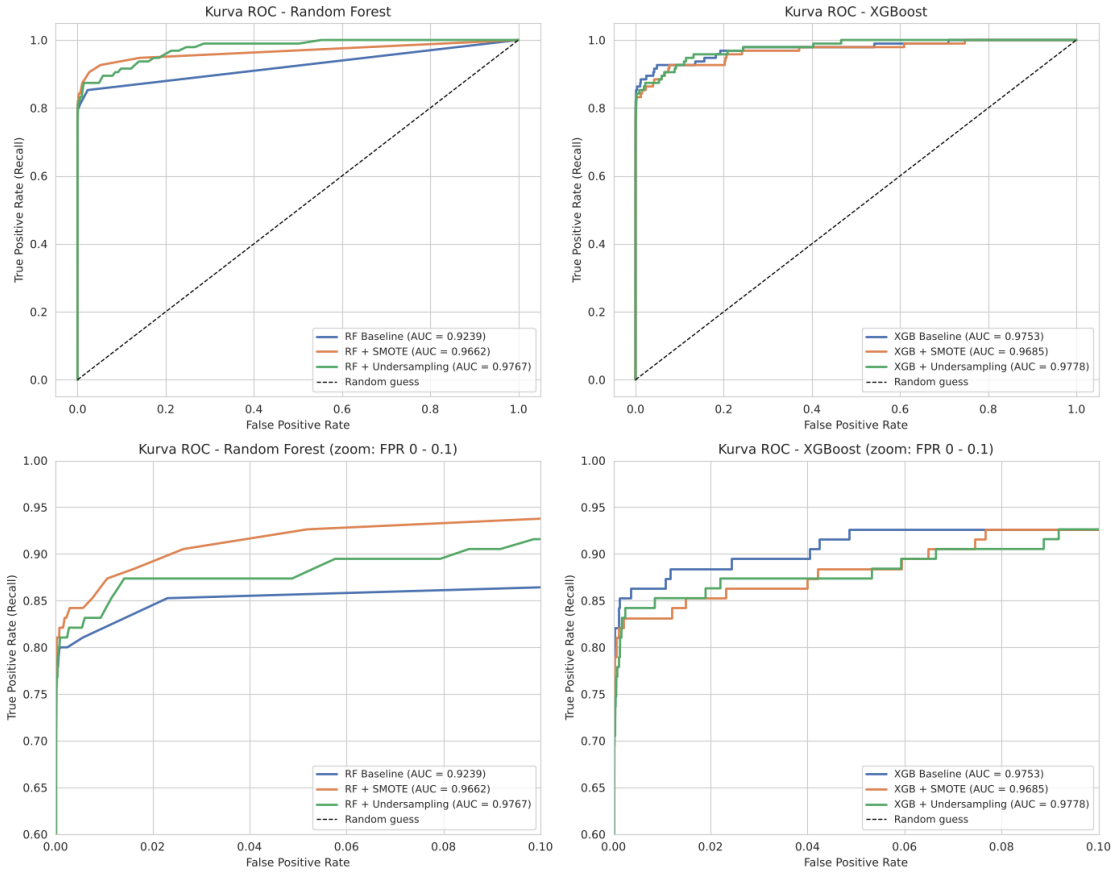
c. Trade-off Precision dan Recall

Gambar 5 memperlihatkan pola yang konsisten: semakin agresif penanganan class imbalance, recall meningkat tetapi precision menurun. Dalam konteks deteksi fraud, kedua jenis kesalahan memiliki konsekuensi berbeda:

- False Negative (FN), yaitu fraud yang lolos, menimbulkan kerugian finansial langsung sehingga umumnya dianggap kesalahan paling mahal.
- False Positive (FP), yaitu transaksi normal yang ditandai fraud, mengganggu nasabah (misalnya kartu diblokir sementara) dan menambah beban kerja tim investigasi.

Sebagai contoh, dibandingkan RF + SMOTE, RF + Undersampling menangkap 11 fraud tambahan (83 vs 72), tetapi menghasilkan 889 false alarm tambahan (896 vs 7). Artinya, untuk setiap satu fraud tambahan, sekitar 81 nasabah normal ikut terganggu. Beban sebesar ini umumnya tidak dapat diterima, sehingga recall tertinggi belum tentu menjadi pilihan terbaik.

d. Analisis Kurva ROC



Gambar 6. Kurva ROC setiap skenario (atas: kurva lengkap, bawah: diperbesar pada FPR 0–0,1)

Gambar 6 menunjukkan bahwa seluruh skenario memiliki AUC-ROC yang tinggi (0,92–0,98). Pada Random Forest, SMOTE dan undersampling meningkatkan AUC-ROC secara nyata dibandingkan baseline. Pada XGBoost, nilai AUC-ROC ketiga skenario relatif mirip. Temuan yang menarik, AUC-ROC tertinggi justru dimiliki skenario undersampling (0,9767 dan 0,9778), padahal F1-score-nya paling rendah. Hal ini menunjukkan bahwa model undersampling sebenarnya masih mampu mengurutkan transaksi dari yang paling mencurigakan, tetapi threshold default 0,5 menjadi terlalu rendah karena probabilitas fraud "membengkak" akibat data latih yang dibuat seimbang. Dengan demikian, AUC-ROC yang tinggi tidak menjamin performa yang baik pada threshold yang digunakan, sehingga metrik ini perlu dibaca bersama precision, recall, dan confusion matrix.

e. Mengapa Accuracy Saja Tidak Cukup

Model "bodoh" yang selalu memprediksi transaksi normal sudah memperoleh accuracy 0,9983 pada data uji tanpa mendeteksi satu pun fraud. Empat skenario (kedua baseline dan kedua skenario SMOTE) memiliki accuracy yang hampir sama, yaitu 0,9991–0,9995, padahal jumlah fraud yang lolos (20–26) dan false alarm-nya (2–29) berbeda. Lebih jauh lagi, kedua skenario undersampling memiliki accuracy lebih rendah daripada model "bodoh" tersebut (0,9840 dan 0,9713), padahal keduanya mendeteksi 83 dari 95 fraud.

Jika hanya melihat accuracy, kita akan menyimpulkan bahwa model yang tidak mendeteksi fraud sama sekali adalah yang terbaik. Kesimpulan ini jelas keliru. Karena kelas normal mencakup 99,83% data, nilai accuracy hampir seluruhnya ditentukan oleh kelas normal dan tidak mencerminkan kemampuan model mendeteksi fraud. Oleh karena itu, evaluasi pada dataset yang sangat tidak seimbang harus menggunakan precision, recall, F1-score kelas minoritas, AUC-ROC, dan confusion matrix.

f. Efisiensi Waktu Training

Berdasarkan pengukuran waktu pada notebook, Random Forest membutuhkan waktu training paling lama, yaitu sekitar 1,5 menit untuk baseline dan sekitar 2,7 menit dengan SMOTE. SMOTE kira-kira menggandakan waktu training karena data latihnya dua kali lebih besar. XGBoost jauh lebih cepat, yaitu sekitar 5–9 detik, sedangkan skenario undersampling selesai dalam waktu kurang dari 1 detik karena data latihnya sangat kecil. Nilai absolut waktu training dapat berbeda di perangkat lain, tetapi perbandingan relatifnya tetap berlaku.

5. Kesimpulan

Berdasarkan hasil praktikum, dapat disimpulkan bahwa:

- Dataset Credit Card Fraud Detection sangat tidak seimbang, dengan transaksi fraud hanya 0,17% (rasio sekitar 599:1). Akibatnya, accuracy tidak dapat digunakan sebagai ukuran utama: model yang tidak mendeteksi fraud sama sekali pun memperoleh accuracy 99,83%.
- Ensemble method (Random Forest dan XGBoost) sudah bekerja cukup baik tanpa penanganan class imbalance, dengan F1-score kelas fraud sebesar 0,8313 dan 0,8214.
- SMOTE meningkatkan recall pada kedua model. Efeknya paling baik pada Random Forest, yaitu 3 fraud tambahan terdeteksi dengan hanya 5 false alarm tambahan. Pada XGBoost, SMOTE justru menurunkan F1-score karena false alarm meningkat cukup besar. Artinya, SMOTE tidak selalu lebih baik dan efeknya bergantung pada algoritma yang digunakan.
- Undersampling menghasilkan recall tertinggi (87,37%), tetapi tidak cocok untuk dataset ini karena membuang 99,83% data normal sehingga menghasilkan ratusan hingga ribuan false alarm.
- Model yang paling seimbang adalah Random Forest + SMOTE, yang mendeteksi 72 dari 95 fraud dengan hanya 7 false alarm dari 56.651 transaksi normal, serta memiliki F1-score yang hampir setara dengan skor tertinggi. Jika prioritasnya adalah meminimalkan false alarm, Random Forest tanpa SMOTE juga layak dipilih. Pemilihan model akhir sebaiknya mempertimbangkan perbandingan biaya fraud yang lolos dengan biaya false alarm dalam konteks bisnis.

Sebagai pengembangan, teknik lain seperti cost-sensitive learning atau penyesuaian threshold klasifikasi dapat dicoba untuk memperbaiki keseimbangan antara precision dan recall.