

Laporan Praktikum 2 Praproses Data
Kadek Nathania Gavrila Astika – 5054251050

1. Latar Belakang

Praproses data merupakan tahapan penting dalam proses data mining dan machine learning karena kualitas data sangat memengaruhi hasil analisis maupun performa model yang akan dibangun. Dataset yang masih mengandung nilai hilang (missing value), outlier, serta atribut yang memiliki skala berbeda dapat menyebabkan hasil prediksi menjadi kurang akurat.

Pada praktikum ini digunakan dataset House Prices – Advanced Regression Techniques yang terdiri dari 1.460 data dan 81 atribut. Dataset tersebut berisi berbagai karakteristik rumah, seperti luas bangunan, kualitas bangunan, kondisi lingkungan, hingga harga jual rumah (SalePrice).

Tujuan praktikum adalah melakukan tahapan praproses data yang meliputi pembersihan data, penanganan missing value, deteksi dan penanganan outlier, transformasi data menggunakan standarisasi dan one-hot encoding, serta reduksi dimensi menggunakan analisis korelasi dan Principal Component Analysis (PCA). Hasil akhir berupa dataset yang lebih bersih dan siap digunakan untuk proses pemodelan.

2. Metodologi Penelitian

Metodologi yang digunakan pada praktikum terdiri dari beberapa tahapan praproses data sebagai berikut.

1. Pengumpulan Data

Dataset House Prices diimpor menggunakan pustaka Pandas. Data awal memiliki 1.460 baris dan 81 kolom yang terdiri atas atribut numerik dan kategorikal.

2. Pembersihan Data

Tahap pertama adalah mengidentifikasi nilai hilang pada setiap atribut. Kolom yang memiliki persentase missing value lebih dari 50% dihapus karena dianggap memiliki informasi yang terlalu sedikit. Kolom yang dihapus yaitu [PoolQC], [MiscFeature], [Alley], [Fence], dan [MasVnrType]

Nilai hilang pada atribut yang tersisa kemudian diisi menggunakan metode yang sesuai sehingga seluruh missing value berhasil dihilangkan. Setelah proses pembersihan, ukuran dataset menjadi 1.460×76 .

3. Deteksi dan Penanganan Outlier

Outlier dideteksi menggunakan metode Interquartile Range (IQR) pada seluruh atribut numerik. Nilai yang berada di luar batas bawah maupun batas atas tidak dihapus, melainkan ditangani menggunakan teknik capping, yaitu membatasi nilai ekstrem ke batas IQR agar jumlah data tetap dipertahankan.

4. Transformasi Data

Transformasi dilakukan dalam dua tahap:

- Standardisasi atribut numerik menggunakan StandardScaler sehingga setiap fitur memiliki rata-rata mendekati 0 dan standar deviasi mendekati 1.
- One-Hot Encoding pada 38 atribut kategorikal sehingga data kategorikal berubah menjadi representasi numerik.

Setelah kedua proses tersebut, jumlah fitur meningkat menjadi 243 atribut.


5. Reduksi Dimensi

Reduksi dimensi dilakukan menggunakan dua metode, yaitu dengan menghapus atribut yang memiliki korelasi absolut lebih dari 0,8 dan menerapkan Principal Component Analysis (PCA) untuk mempertahankan minimal 95% variasi data. Hasil PCA menghasilkan 67 komponen utama dari total 240 fitur.

3. Hasil Praproses Data

Dataset awal terdiri dari 1.460 baris dan 81 atribut. Hasil pemeriksaan menunjukkan beberapa atribut memiliki persentase missing value yang sangat tinggi, bahkan mendekati 100%, sehingga lima kolom dihapus dari dataset.


Setelah penghapusan kolom dan imputasi nilai hilang, seluruh missing value berhasil dihilangkan tanpa mengurangi jumlah baris data. Dataset akhir pada tahap ini berukuran 1.460×76 .



Gambar 3.1 Boxplot sebelum penanganan outlier

Penghapusan kolom dengan missing value tinggi dilakukan agar kualitas informasi meningkat dan mengurangi risiko bias pada analisis. Sementara itu, imputasi memungkinkan seluruh data tetap dapat digunakan tanpa kehilangan observasi.

Deteksi menggunakan metode IQR menunjukkan beberapa atribut memiliki jumlah outlier yang cukup tinggi, seperti EnclosedPorch dan BsmtFinSF2. Penanganan dilakukan menggunakan teknik capping, sehingga nilai ekstrem dibatasi pada rentang IQR.



Gambar 3.2 Boxplot sesudah penanganan outlier


Teknik capping dipilih karena mampu mengurangi pengaruh nilai ekstrem tanpa menghapus data. Jumlah baris tetap 1.460, sehingga seluruh observasi masih dipertahankan untuk proses analisis berikutnya. Boxplot setelah penanganan menunjukkan penyebaran data menjadi lebih stabil dibandingkan sebelumnya.

Atribut numerik berhasil distandarisasi sehingga memiliki rata-rata mendekati 0 dan standar deviasi sekitar 1. Selain itu, 38 atribut kategorikal berhasil diubah menjadi variabel numerik menggunakan One-Hot Encoding. Akibat proses encoding, jumlah fitur meningkat dari 76 menjadi 243 atribut.

Standarisasi diperlukan karena PCA dan berbagai algoritma machine learning sensitif terhadap perbedaan skala antar fitur. Sementara itu, One-Hot Encoding memungkinkan atribut kategorikal diproses oleh algoritma yang membutuhkan data numerik.


Reduksi dimensi dilakukan untuk mengurangi jumlah fitur yang memiliki informasi berulang (redundan) sehingga dataset menjadi lebih efisien tanpa kehilangan banyak informasi penting. Tahap pertama dilakukan dengan menganalisis korelasi antar atribut numerik menggunakan heatmap. Atribut yang memiliki nilai korelasi absolut lebih dari 0,8 dianggap memiliki hubungan yang sangat kuat, sehingga salah satu atribut pada pasangan tersebut dihapus.

Beberapa pasangan atribut dengan korelasi tinggi yang ditemukan antara lain GarageArea–GarageCars, TotalBsmtSF–1stFlrSF, dan GrLivArea–TotRmsAbvGrd. Penghapusan atribut dilakukan untuk mengurangi multikolinearitas dan redundansi pada data.



Gambar 3.3 Heatmap korelasi atribut numerik

Setelah analisis korelasi, dilakukan reduksi dimensi menggunakan Principal Component Analysis (PCA). PCA mentransformasikan fitur-fitur asli menjadi sekumpulan komponen utama yang mampu merepresentasikan sebagian besar variasi data. Berdasarkan hasil perhitungan, diperoleh 67 komponen utama yang telah mampu mempertahankan sekitar 95% informasi atau variasi dari dataset.



Gambar 3.4 Visualisasi dua komponen utama PCA

4. Kesimpulan

Berdasarkan praktikum praproses data pada dataset House Prices, dapat disimpulkan bahwa seluruh tahapan praproses berhasil dilakukan dengan baik. Dataset awal yang terdiri dari 1.460 baris dan 81 atribut dibersihkan melalui penghapusan kolom dengan missing value tinggi dan imputasi nilai hilang hingga tidak terdapat data kosong.

Outlier berhasil ditangani menggunakan metode IQR capping tanpa mengurangi jumlah observasi. Selanjutnya, atribut numerik distandarisasi dan atribut kategorikal diubah menggunakan One-Hot Encoding, sehingga seluruh fitur dapat direpresentasikan dalam bentuk numerik.

Tahap reduksi dimensi menggunakan analisis korelasi dan Principal Component Analysis (PCA) berhasil menurunkan jumlah fitur menjadi 67 komponen utama dengan tetap mempertahankan 95% informasi variansi data. Dataset hasil praproses menjadi lebih bersih, lebih efisien, dan siap digunakan untuk proses pemodelan machine learning.