

Laporan Analisis Scrapping dan EDA rawg.io

1. Deskripsi Dataset

Dataset yang digunakan dalam praktikum ini diperoleh melalui RAWG API dan berisi informasi mengenai game. Dataset terdiri dari 1.600 data dengan 8 atribut, yaitu id, name, released, rating, ratings_count, metacritic, playtime, dan genres.

Atribut id merupakan identitas unik setiap game, sedangkan name menunjukkan nama atau judul game. Atribut released menunjukkan tanggal perilisan game. Atribut rating menunjukkan rata-rata penilaian pengguna, sementara ratings_count menunjukkan jumlah pengguna yang memberikan penilaian. Atribut metacritic merupakan skor Metacritic, playtime menunjukkan perkiraan waktu bermain dalam jam, dan genres menunjukkan genre yang dimiliki oleh setiap game.

Atribut id, ratings_count, metacritic, dan playtime termasuk atribut numerik, name dan genres merupakan atribut kategorikal nominal, sedangkan released merupakan atribut temporal. Karena satu game dapat memiliki lebih dari satu genre, atribut genres dapat memuat beberapa kategori dalam satu data.

2. Statistik Deskriptif

Statistik deskriptif dilakukan terhadap atribut numerik yang meliputi rating, ratings_count, metacritic, dan playtime. Hasil analisis menunjukkan bahwa atribut rating memiliki rata-rata 3,62, median 3,73, modus 4,37, dan standar deviasi 0,59. Nilai rating berada pada rentang 1,68 hingga 4,75.

Atribut ratings_count memiliki rata-rata 689,47, median 430, modus 179, dan standar deviasi 756,58. Jumlah rating berkisar antara 30 hingga 7.441. Sementara itu, atribut metacritic memiliki rata-rata 78,97, median 80, modus 80, dan standar deviasi 8,46, dengan nilai minimum 40 dan maksimum 99.

Atribut playtime memiliki rata-rata 5,61 jam, median 4 jam, modus 3 jam, dan standar deviasi 11,08. Nilai playtime berada pada rentang 0 hingga 329 jam. Perbedaan yang cukup besar antara rata-rata dan median, terutama pada playtime, menunjukkan adanya beberapa nilai dengan waktu bermain yang jauh lebih tinggi dibandingkan sebagian besar data.

Pada atribut kategorikal, distribusi genre menunjukkan bahwa Action merupakan genre yang paling banyak ditemukan dengan 1.083 data, diikuti oleh Adventure sebanyak 607 data dan Indie sebanyak 532 data. Genre dengan jumlah paling sedikit adalah Board Games sebanyak 7 data.

3. Penanganan Data

Pemeriksaan nilai hilang menunjukkan bahwa sebagian besar atribut tidak memiliki missing value. Atribut released memiliki 3 nilai hilang (0,19%), sedangkan genres juga memiliki 3 nilai hilang (0,19%). Atribut metacritic memiliki jumlah missing

value paling banyak, yaitu 289 data (18,06%). Sementara itu, atribut id, name, rating, ratings_count, dan playtime tidak memiliki nilai hilang.


Nilai hilang pada released dan genres dipertahankan karena jumlahnya sangat kecil dan tidak mengganggu analisis secara keseluruhan. Nilai hilang pada metacritic juga tidak diisi secara sembarang karena tidak terdapat informasi yang cukup untuk menentukan skor Metacritic yang sebenarnya. Oleh karena itu, data tersebut dipertahankan sebagai nilai kosong dan tidak digunakan pada analisis yang membutuhkan nilai metacritic.

Identifikasi outlier dilakukan menggunakan metode Interquartile Range (IQR). Hasil analisis menunjukkan terdapat 26 outlier pada rating, 134 outlier pada ratings_count, 18 outlier pada metacritic, dan 131 outlier pada playtime.

Outlier tidak langsung dihapus karena nilai tersebut masih dapat merepresentasikan kondisi sebenarnya dari dataset. Sebagai contoh, game yang sangat populer dapat memiliki jumlah rating jauh lebih tinggi dibandingkan game lainnya, sedangkan game tertentu dapat memiliki waktu bermain yang sangat panjang. Oleh karena itu, outlier dipertahankan dan dipertimbangkan dalam proses interpretasi data.


4. Visualisasi dan Interpretasi

Visualisasi dilakukan menggunakan histogram, bar chart, scatter plot, correlation heatmap, dan boxplot. Histogram digunakan untuk melihat distribusi atribut numerik, sedangkan bar chart digunakan untuk membandingkan jumlah game berdasarkan genre.




Histogram menunjukkan pola distribusi dari masing-masing atribut numerik. Distribusi rating cenderung terkonsentrasi pada nilai sekitar 3,5–4,4, dengan frekuensi tertinggi berada di sekitar rating 3,8–4,0. Atribut ratings_count memiliki distribusi yang miring ke kanan (right-skewed) karena sebagian besar game memiliki jumlah rating yang relatif rendah, sementara hanya sebagian kecil game memiliki jumlah rating yang sangat tinggi. Distribusi metacritic cenderung terkonsentrasi di sekitar nilai 75–90 dengan bentuk yang relatif mendekati distribusi normal. Sementara itu, playtime juga


menunjukkan distribusi yang sangat miring ke kanan, karena sebagian besar game memiliki playtime yang rendah, sedangkan hanya sedikit game yang memiliki waktu bermain jauh lebih tinggi.




Berdasarkan distribusi genre, Action merupakan genre yang paling dominan dalam dataset dengan jumlah game paling banyak, diikuti oleh Adventure dan Indie. Sementara itu, genre dengan jumlah game paling sedikit pada grafik 10 genre teratas adalah Puzzle. Hal ini menunjukkan bahwa komposisi genre dalam dataset tidak merata, dengan beberapa genre memiliki jumlah data yang jauh lebih banyak dibandingkan genre lainnya.



Scatter plot digunakan untuk melihat hubungan antara rating dan metacritic. Terlihat adanya hubungan positif antara rating pengguna dan skor Metacritic, yang menunjukkan bahwa game dengan rating pengguna yang lebih tinggi cenderung memiliki skor Metacritic yang lebih tinggi pula. Meskipun demikian, titik-titik data masih cukup tersebar, sehingga hubungan tersebut tidak sepenuhnya linear. Hal ini menunjukkan bahwa rating pengguna bukan satu-satunya faktor yang berkaitan dengan skor Metacritic.



Correlation heatmap digunakan untuk melihat tingkat hubungan antaratribut numerik. Korelasi paling kuat terdapat antara rating dan metacritic dengan nilai 0,62, yang menunjukkan hubungan positif dengan tingkat kekuatan sedang hingga cukup kuat. Rating juga memiliki korelasi positif dengan ratings_count sebesar 0,47, sedangkan ratings_count dan metacritic memiliki korelasi sebesar 0,40. Sementara itu, playtime memiliki korelasi yang relatif lemah terhadap atribut lainnya, dengan nilai korelasi antara 0,20 hingga 0,29. Secara keseluruhan, atribut numerik dalam dataset memiliki hubungan positif, tetapi tidak terdapat korelasi yang sangat kuat antaratribut.



Boxplot digunakan untuk membandingkan distribusi rating pada lima genre dengan jumlah data terbanyak. Median rating pada Action, RPG, Shooter, dan Adventure berada di kisaran 3,7–3,8, sedangkan Indie memiliki median yang sedikit lebih rendah, yaitu sekitar 3,6. Distribusi rating kelima genre relatif serupa, dengan sebagian besar data berada pada kisaran sekitar 3,1 hingga 4,2. Selain itu, terdapat beberapa outlier dengan

rating rendah, terutama pada Action, RPG, Adventure, dan Indie. Hal ini menunjukkan bahwa meskipun sebagian besar game memiliki rating yang relatif tinggi, terdapat sejumlah game dengan rating yang jauh lebih rendah dibandingkan mayoritas data.