Laporan Praktikum 5
Sequential Pattern Analysis
Kadek Nathania Gavrila Astika – 5054251050

1. Latar Belakang

Dalam bisnis ritel, mengetahui produk yang dibeli pelanggan belum cukup untuk memahami kebiasaan belanja mereka. Peritel juga perlu mengetahui urutan pembelian dari waktu ke waktu, misalnya produk yang cenderung dibeli kembali atau produk lain yang dibeli setelahnya. Informasi ini dapat dimanfaatkan untuk mengelola stok, mengirim pengingat pembelian ulang, dan menyusun rekomendasi produk.

Untuk menganalisis hal tersebut, digunakan pendekatan Sequential Pattern Mining. Berbeda dengan Association Rule Mining yang hanya melihat hubungan antarproduk dalam satu transaksi, pendekatan ini memperhatikan urutan pembelian pada transaksi yang berbeda. Pada praktikum ini, algoritma PrefixSpan diterapkan karena lebih efisien dibandingkan GSP. PrefixSpan mencari pola melalui proyeksi data berdasarkan prefix tanpa membangkitkan kandidat pola secara berulang.

Tujuan praktikum ini adalah memahami konsep Sequential Pattern Analysis, menerapkan algoritma PrefixSpan pada data transaksi ritel, serta mengevaluasi pola yang ditemukan menggunakan metrik support dan confidence.

2. Dataset

Dataset yang digunakan adalah Online Retail dari UCI Machine Learning Repository, yaitu file Online Retail.xlsx yang berukuran 541.909 baris × 8 kolom. Dataset ini berisi catatan transaksi sebuah toko ritel online di Inggris selama periode 1 Desember 2010 hingga 9 Desember 2011. Dataset mencakup 25.900 invoice, 4.070 kode produk, 4.372 pelanggan, dan 38 negara. Setiap baris merepresentasikan suatu item dalam transaksi. Adapun atribut yang tersedia meliputi:

Tabel 1. Atribut dataset Online Retail

Atribut	Keterangan
InvoiceNo	Nomor identifikasi transaksi
StockCode	Kode identifikasi produk
Description	Nama atau deskripsi produk
Quantity	Jumlah produk yang dibeli
InvoiceDate	Tanggal dan waktu transaksi
UnitPrice	Harga satuan produk
CustomerID	**I**dentitas pelanggan
Country	Negara asal pelanggan

Dalam analisis pola berurutan, CustomerID digunakan sebagai identitas sequence, InvoiceDate sebagai penentu urutan waktu, InvoiceNo sebagai dasar pengelompokan itemset, dan Description sebagai item.

3. Metodologi

Analisis dilakukan menggunakan Python dengan pustaka pandas, NumPy, Matplotlib, dan Seaborn melalui tahapan berikut.

a. Eksplorasi data: memeriksa dimensi dan tipe data, nilai kosong, transaksi batal, nilai Quantity yang tidak valid, serta rentang tanggal transaksi.
b. Pembersihan data: menghapus baris tanpa Description, transaksi batal, baris dengan Quantity ≤ 0, baris tanpa CustomerID, serta item non-produk. Penulisan Description juga diseragamkan dengan menghapus spasi berlebih.
c. Penyusunan sequence: mengurutkan data berdasarkan CustomerID dan InvoiceDate, menggabungkan produk dalam satu invoice menjadi satu itemset, lalu menyusun itemset setiap pelanggan menjadi satu sequence dalam bentuk list of list.
d. Penerapan PrefixSpan: mencari pola pembelian berurutan dengan implementasi PrefixSpan yang mempertahankan struktur itemset. Minimum support awal ditetapkan 0,01, lalu dibandingkan dengan beberapa nilai lain untuk menentukan parameter yang paling sesuai. Hasilnya divalidasi dengan perhitungan brute force pada 20 pola sampel.

e. Evaluasi pola: menilai pola menggunakan support, yaitu proporsi pelanggan yang memiliki pola tersebut, dan confidence, yaitu proporsi pelanggan dengan urutan prefix yang kemudian melanjutkan pembelian sesuai pola. Pola juga dibedakan menjadi pembelian ulang dan lintas produk, serta dihitung median jeda waktu pembelian untuk tiga pola terbaik.

4. Hasil dan Pembahasan

a. Eksplorasi dan Pembersihan Data

Hasil eksplorasi menunjukkan bahwa dataset awal memiliki 541.909 baris, 25.900 invoice, 4.372 pelanggan, dan 4.223 produk. Hasil pemeriksaan kualitas data ditampilkan pada Tabel 2.

Tabel 2. Hasil pemeriksaan kualitas data mentah

Temuan	Jumlah baris
CustomerID kosong	135.080 (24,9%)
Quantity ≤ 0	10.624
Invoice batal (diawali huruf C)	9.288
Description kosong	1.454

Masalah terbesar ditemukan pada atribut CustomerID, yaitu sekitar seperempat data tidak memiliki identitas pelanggan. Selain itu, nilai Quantity berkisar antara −80.995 hingga 80.995, dan terdapat nilai UnitPrice yang negatif. Eksplorasi juga menemukan item yang bukan merupakan produk dagangan, seperti POSTAGE, CARRIAGE, Manual, dan Bank Charges, serta nama produk yang sama tetapi ditulis berbeda karena spasi ganda.

Setelah proses pembersihan dilakukan, jumlah data berkurang secara bertahap seperti ditunjukkan pada Tabel 3.

Tabel 3. Jumlah baris pada setiap tahap pembersihan data

Tahap	Jumlah baris	Baris terhapus
Data awal	541.909	0
Hapus Description kosong	540.455	1.454
Hapus invoice batal (C…)	531.167	9.288
Hapus Quantity ≤ 0	530.693	474
Hapus CustomerID kosong	397.924	132.769
Hapus item non-produk	396.370	1.554

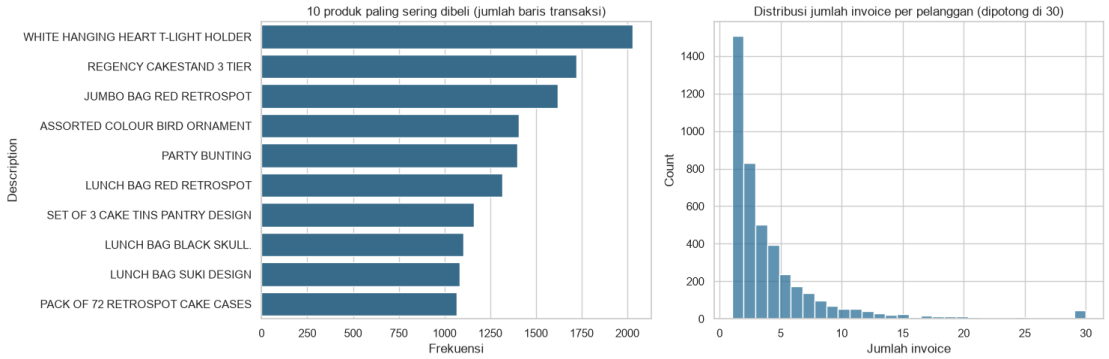
Penghapusan terbesar terjadi pada tahap penghapusan CustomerID kosong, yaitu sebanyak 132.769 baris. Sementara itu, penghapusan Quantity kurang dari atau sama dengan nol hanya mengurangi 474 baris karena sebagian besar data tersebut telah terhapus saat transaksi batal dihilangkan. Perbandingan jumlah data sebelum dan sesudah pembersihan ditampilkan pada Tabel 4.

Tabel 4. Perbandingan data sebelum dan sesudah pembersihan

Ukuran	Sebelum	Sesudah	% tersisa
Jumlah baris	541.909	396.370	73,1
Jumlah invoice	25.900	18.405	71,1
Jumlah pelanggan	4.372	4.335	99,2
Jumlah produk	4.223	3.852	91,2

Meskipun jumlah baris berkurang menjadi 73,1%, sebanyak 99,2% pelanggan tetap dapat dipertahankan. Artinya, proses pembersihan tidak banyak mengurangi cakupan pelanggan yang menjadi dasar analisis.

Selanjutnya, dilakukan eksplorasi terhadap produk yang paling sering dibeli dan distribusi jumlah invoice per pelanggan pada data yang telah dibersihkan. Hasilnya ditampilkan pada Gambar 1.



Gambar 1. Sepuluh produk paling sering dibeli (kiri) dan distribusi jumlah invoice per pelanggan (kanan) setelah pembersihan

Produk yang paling sering dibeli didominasi oleh barang dekorasi rumah dan perlengkapan dapur, seperti White Hanging Heart T-Light Holder, Regency Cakestand 3 Tier, dan Jumbo Bag Red Retrospot. Distribusi invoice menunjukkan bahwa sebagian besar pelanggan hanya melakukan sedikit transaksi. Jumlah invoice per pelanggan memiliki rata-rata 4,25 dan median 2, dengan jumlah maksimum 206 invoice. Dari 4.335 pelanggan, sebanyak 2.829 pelanggan atau 65,3% memiliki minimal dua invoice. Hanya pelanggan tersebut yang memiliki riwayat transaksi yang memungkinkan terbentuknya pola pembelian berurutan.

b. Hasil Penyusunan Sequence

Data bersih kemudian disusun menjadi 4.335 sequence pelanggan. Setiap sequence memiliki rata-rata 4,25 itemset, sedangkan setiap itemset rata-rata berisi 20,98 produk.

Hasil ini menunjukkan bahwa satu invoice dapat memuat banyak produk yang dibeli secara bersamaan. Oleh karena itu, pengelompokan produk berdasarkan invoice tetap dipertahankan selama proses analisis agar urutan pembelian tidak keliru diinterpretasikan.

c. Penentuan Minimum Support

Pengujian awal menggunakan minimum support 0,01 menghasilkan 47.062 pola dengan waktu komputasi sekitar 426,6 detik. Jumlah tersebut terlalu besar untuk dianalisis secara efektif. Oleh karena itu, dilakukan perbandingan dengan beberapa nilai minimum support lainnya seperti ditunjukkan pada Tabel 5.

Tabel 5. Jumlah pola berdasarkan nilai minimum support

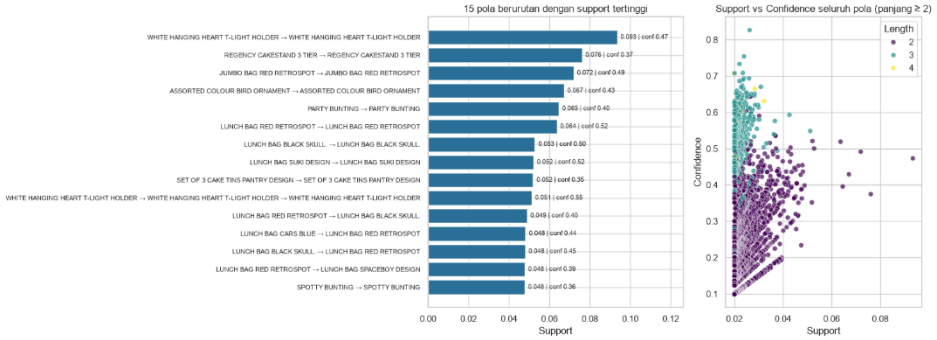
Min. support	Min. pelanggan	Total pola	Pola panjang 1	Pola panjang ≥ 2	Panjang maksimum
0,050	217	274	264	10	3
0,040	174	479	420	59	3
0,030	131	949	655	294	4
0,025	109	1.494	821	673	4
0,020	87	3.017	1.044	1.973	4
0,015	66	8.023	1.348	6.675	5
0,010	44	47.062	1.759	45.303	7

Jumlah pola meningkat seiring dengan penurunan minimum support. Pada nilai 0,01, pola yang dihasilkan sangat banyak, sedangkan nilai 0,04 dan 0,05 hanya menghasilkan sedikit pola dengan panjang minimal dua. Berdasarkan perbandingan tersebut, minimum support 0,02 dipilih karena menghasilkan jumlah pola yang cukup representatif dan masih dapat dianalisis. Pada nilai ini, algoritma menghasilkan 3.017 pola, dengan 1.973 pola memiliki panjang minimal dua. Pola tersebut terdiri atas 1.514 pola panjang dua, 453 pola panjang tiga, dan enam pola panjang empat.

Validasi terhadap 20 pola sampel juga menunjukkan bahwa seluruh nilai count hasil PrefixSpan sesuai dengan perhitungan *brute force*. Dengan demikian, hasil implementasi yang digunakan telah melalui pemeriksaan terhadap sampel pola.

d. Hasil dan Evaluasi Pola Berurutan

Dari 3.017 pola yang dihasilkan, terdapat 1.973 pola dengan panjang minimal dua. Nilai support pola-pola tersebut berkisar antara 0,020 hingga 0,093, sedangkan confidence berkisar antara 0,099 hingga 0,826. Rata-rata support sebesar 0,025 dan rata-rata confidence sebesar 0,323. Gambar 2 menampilkan 15 pola dengan support tertinggi serta sebaran support dan confidence seluruh pola berurutan.



Gambar 2. Lima belas pola berurutan dengan support tertinggi (kiri) dan sebaran support terhadap confidence seluruh pola (kanan)

Pola dengan support tertinggi didominasi oleh pola pembelian ulang, yaitu pelanggan membeli produk yang sama pada transaksi berikutnya. Padahal, dari seluruh pola yang ditemukan, hanya 162 merupakan pola pembelian ulang, sedangkan 1.811 lainnya melibatkan produk berbeda. Sebaran pada grafik kanan juga menunjukkan bahwa pola dengan panjang tiga umumnya memiliki confidence lebih tinggi, tetapi support-nya lebih rendah dibandingkan pola dengan panjang dua.
Tiga pola dengan support tertinggi beserta support prefix dan median jeda waktu pembeliannya ditampilkan pada Tabel 6.

Tabel 6. Tiga pola berurutan terbaik berdasarkan support

No.	Pola	Jumlah pelanggan	Support prefix	Support	Confidence	Median jeda (hari)
1	WHITE HANGING HEART T-LIGHT HOLDER → WHITE HANGING HEART T-LIGHT HOLDER	405	0,1975	0,0934	0,4731	75
2	REGENCY CAKESTAND 3 TIER → REGENCY CAKESTAND 3 TIER	330	0,2032	0,0761	0,3746	73
3	JUMBO BAG RED RETROSPOT → JUMBO BAG RED RETROSPOT	312	0,1465	0,0720	0,4913	88

White Hanging Heart T-Light Holder memiliki support tertinggi, yaitu 0,0934. Sebanyak 405 pelanggan tercatat membeli produk tersebut dan kembali membelinya pada transaksi berikutnya. Confidence sebesar 0,4731 menunjukkan bahwa sekitar 47% pelanggan yang pernah membeli produk ini kembali membelinya, dengan median jeda 75 hari. Oleh karena itu, ketersediaan stok produk ini perlu dijaga, dan pengingat pembelian ulang dapat dikirim sekitar dua hingga tiga bulan setelah pembelian pertama.
Regency Cakestand 3 Tier memiliki support prefix tertinggi, yaitu 0,2032, tetapi confidence pembelian ulangnya lebih rendah dibandingkan dua produk lainnya. Produk ini juga memiliki pola lintas produk dengan Set of 3 Regency Cake Tins dengan support 0,0475, sehingga dapat dipertimbangkan sebagai produk awal untuk menawarkan produk lain dalam seri yang sama.
Sementara itu, Jumbo Bag Red Retrospot memiliki confidence tertinggi di antara ketiga pola, yaitu 0,4913, dengan median jeda pembelian 88 hari. Hasil ini menunjukkan bahwa hampir separuh pelanggan yang pernah

membeli produk tersebut kembali membelinya pada transaksi berikutnya, sehingga produk ini sesuai untuk promosi pembelian ulang.

Selain pembelian ulang, pola lintas produk juga memberikan informasi mengenai hubungan pembelian antarproduk. Lima pola lintas produk dengan support tertinggi ditampilkan pada Tabel 7.

Tabel 7. Lima pola lintas produk dengan support tertinggi

Pola	Jumlah pelanggan	Support	Confidence
LUNCH BAG RED RETROSPOT → LUNCH BAG BLACK SKULL.	212	0,0489	0,3985
LUNCH BAG CARS BLUE → LUNCH BAG RED RETROSPOT	209	0,0482	0,4363
LUNCH BAG BLACK SKULL. → LUNCH BAG RED RETROSPOT	208	0,0480	0,4541
LUNCH BAG RED RETROSPOT → LUNCH BAG SPACEBOY DESIGN	207	0,0478	0,3891
LUNCH BAG RED RETROSPOT → LUNCH BAG SUKI DESIGN	206	0,0475	0,3872

Kelima pola tersebut didominasi oleh produk dari keluarga Lunch Bag dengan motif berbeda. Bahkan, hubungan pembelian ditemukan dalam dua arah, seperti Red Retrospot ke Black Skull dan sebaliknya. Hal ini menunjukkan adanya kecenderungan pelanggan untuk membeli variasi produk dari seri yang sama.

Sebagai pelengkap, dilakukan pemeringkatan berdasarkan confidence untuk melihat pola dengan kemungkinan kelanjutan pembelian tertinggi. Hasilnya ditampilkan pada Tabel 8.

Tabel 8. Lima pola berurutan dengan confidence tertinggi

Pola	Jumlah pelanggan	Support	Confidence
JUMBO BAG RED RETROSPOT → JUMBO BAG DOILEY PATTERNS → JUMBO BAG RED RETROSPOT	114	0,0263	0,8261
JUMBO BAG RED RETROSPOT → JUMBO BAG DOILEY PATTERNS → JUMBO BAG VINTAGE DOILY	104	0,0240	0,7536
LUNCH BAG RED RETROSPOT → LUNCH BAG DOILEY PATTERN → LUNCH BAG RED RETROSPOT	96	0,0221	0,7328
JUMBO BAG RED RETROSPOT → LUNCH BAG CARS BLUE → JUMBO BAG RED RETROSPOT	102	0,0235	0,7083
JUMBO BAG RED RETROSPOT → JUMBO BAG PINK POLKADOT → JUMBO BAG RED RETROSPOT → JUMBO BAG RED RETROSPOT	87	0,0201	0,7073

Pola dengan confidence tertinggi mencapai 0,8261, yang berarti sekitar 82,6% pelanggan yang memiliki urutan pembelian pada prefix tersebut juga melanjutkan pembelian sesuai pola. Namun, support pola ini hanya sebesar 0,0263. Artinya, pola tersebut hanya ditemukan pada sebagian kecil pelanggan. Oleh karena itu, pola dengan confidence tinggi lebih sesuai digunakan untuk rekomendasi berdasarkan riwayat pembelian individu daripada promosi yang ditujukan kepada seluruh pelanggan.

5. Kesimpulan

Berdasarkan hasil praktikum, dataset Online Retail berhasil dibersihkan dari transaksi yang tidak relevan sehingga tersisa 396.370 baris data, 18.405 invoice, dan 4.335 pelanggan. Data tersebut kemudian disusun menjadi sequence berdasarkan urutan transaksi setiap pelanggan.

Penerapan PrefixSpan dengan minimum support 0,02 menghasilkan 1.973 pola berurutan dengan panjang dua hingga empat dan rata-rata confidence 0,323. Nilai tersebut dipilih karena memberikan jumlah pola yang cukup untuk dianalisis tanpa menghasilkan kombinasi berlebihan seperti pada minimum support 0,01. Hasil validasi terhadap 20 pola sampel juga menunjukkan kesesuaian antara perhitungan PrefixSpan dan *brute force*.

Pola yang ditemukan menunjukkan adanya kecenderungan pembelian ulang pada produk seperti White Hanging Heart T-Light Holder, Regency Cakestand 3 Tier, dan Jumbo Bag Red Retrospot, dengan median jeda pembelian sekitar 73 hingga 88 hari. Selain itu, pelanggan juga cenderung membeli variasi produk dari keluarga yang sama, terutama Lunch Bag dan Jumbo Bag.